2. 正则表达式

2.1 概述

- 学习动机

1. 文本数据处理已经成为常见的编程工作之一
2. 对文本内容的**搜索，定位，提取**是逻辑比较复杂的工作
3. 为了快速方便的解决上述问题，产生了*正则表达式技术*

- 定义

即**文本的高级匹配模式**，其本质是由一系列字符和特殊符号构成的字串，这个字串即正则表达式。

- 原理

通过普通字符和有特定含义的字符，来组成字符串，用以描述一定的字符串规则，比如：重复，位置等，来表达某类特定的字符串，进而匹配。

- 学习目标

1. 熟练掌握正则表达式元字符
2. 能够读懂常用正则表达式，编辑简单的正则规则
3. 能够熟练使用re模块操作正则表达式

2.2 元字符使用

- 普通字符

匹配规则：每个普通字符匹配其对应的字符

```
e.g.
In : re.findall('ab',"abcdefabcd")
Out: ['ab', 'ab']
In [20]: re.findall("ab","afggasabfdfab")
Out[20]: ['ab', 'ab']
```

> 注意：正则表达式在python中也可以匹配中文

- 或关系

元字符：`|`

匹配规则: 匹配 | 两侧任意的正则表达式即可

```
e.g.
In : re.findall('com|cn',"www.baidu.com/www.tmooc.cn")
Out: ['com', 'cn']

```

- 匹配单个字符

元字符：`.`

匹配规则：匹配除换行外的任意一个字符

```
e.g.
In : re.findall('张.丰',"张三丰,张四丰,张五丰")
Out: ['张三丰', '张四丰', '张五丰']

```

- 匹配字符集

元字符：`[字符集]`

匹配规则: 匹配字符集中的任意一个字符

表达形式:

> [abc#!好] 表示 [] 中的任意一个字符
> [0-9],[a-z],[A-Z] 表示区间内的任意一个字符
> [_#?0-9a-z] 混合书写，一般区间表达写在后面

```
e.g.
In : re.findall('[aeiou]',"How are you!")
Out: ['o', 'a', 'e', 'o', 'u']
```

- 匹配字符集反集

元字符：`[^字符集]`

匹配规则：匹配除了字符集以外的任意一个字符

```
e.g.
In : re.findall('[^0-9]',"Use 007 port")
Out: ['U', 's', 'e', ' ', ' ', 'p', 'o', 'r', 't']
```

- 匹配字符串开始位置

元字符: `^`

匹配规则：匹配目标字符串的开头位置

```
e.g.
In : re.findall('^Jame',"Jame,hello")
Out: ['Jame']
```

- 匹配字符串的结束位置

元字符: `$`

匹配规则: 匹配目标字符串的结尾位置

```
e.g.
In : re.findall('Jame$',"Hi,Jame")
Out: ['Jame']
```

> 规则技巧: `^` 和 `$` 必然出现在正则表达式的开头和结尾处。如果两者同时出现，则中间的部分必须匹配整个目标字符串的全部内容。

- 匹配字符重复

元字符: `*`

匹配规则：匹配前面的字符出现0次或多次

```
e.g.
In : re.findall('wo*',"wooooo~~w!")
Out: ['wooooo', 'w']
```

元字符: `+`

匹配规则： 匹配前面的字符出现1次或多次

```
e.g.
In : re.findall('[A-Z][a-z]+',"Hello World")
Out: ['Hello', 'World']
```

元字符: `?`

匹配规则： 匹配前面的字符出现0次或1次

```
e.g. 匹配整数
In [28]: re.findall('-?[0-9]+',"Jame,age:18, -26")
Out[28]: ['18', '-26']
```

元字符: `{n}`

匹配规则： 匹配前面的字符出现n次

```
e.g. 匹配手机号码
In : re.findall('1[0-9]{10}',"Jame:13886495728")
Out: ['13886495728']

```

元字符: `{m,n}`

匹配规则： 匹配前面的字符出现m-n次

```
e.g. 匹配qq号
In : re.findall('[1-9][0-9]{5,10}',"Baron:1259296994")
Out: ['1259296994']
```

- 匹配任意（非）数字字符

元字符：`\d` `\D`

匹配规则：`\d` 匹配任意数字字符，`\D` 匹配任意非数字字符

```
e.g. 匹配端口
In : re.findall('\d{1,5}',"Mysql: 3306, http:80")
Out: ['3306', '80']
```

- 匹配任意（非）普通字符

元字符：`\w`

匹配规则: `\w` 匹配普通字符，`\W` 匹配非普通字符

说明: 普通字符指数字，字母，下划线，汉字。

```
e.g.
In : re.findall('\w+',"server_port = 8888")
Out: ['server_port', '8888']
```

- 匹配任意（非）空字符

元字符：`\s` `\S`

crf 匹配规则:`\s`匹配空字符，`\S` 匹配非空字符

说明：空字符指 空格`\r \n \t \v \f` 字符

```
e.g.
In : re.findall('\w+\s+\w+',"hello    world")
Out: ['hello    world']
```

- 匹配（非）单词的边界位置

元字符：`\b` `\B`

匹配规则：`\b` 表示单词边界，`\B` 表示非单词边界

说明：单词边界指数字字母(汉字)下划线与其他字符的交界位置。

```
e.g.
In : re.findall(r'\bis\b',"This is a test.")
Out: ['is']
```

> 注意： 当元字符符号与Python字符串中转义字符冲突的情况则需要使用r将正则表达式字符串声明为原始字符串，如果不确定那些是Python字符串的转义字符，则可以在所有正则表达式前加r。

类别	元字符
匹配字符	`.` `[...]` `[^...]` \d \D \w \W \s \S
匹配重复	`*` `+` `?` `{n}` `{m,n}`
匹配位置	`^` $ \b \B
其他	`|` `()` `\`

2.3 匹配规则

2.3.1 特殊字符匹配

- 目的： 如果匹配的目标字符串中包含正则表达式特殊字符，则在表达式中元字符就想表示其本身含义时就需要进行 \ 处理。

```
特殊字符: . * + ? ^ $ [] () {} | \
```

- 操作方法：在正则表达式元字符前加 \ 则元字符就是去其特殊含义，就表示字符本身

```
e.g. 匹配特殊字符 . 时使用 \. 表示本身含义
In : re.findall('-?\d+\.?\d*',"123,-123,1.23,-1.23")
Out: ['123', '-123', '1.23', '-1.23']
```

2.3.2 贪婪模式和非贪婪模式

- 定义

> 贪婪模式: 默认情况下，匹配重复的元字符总是尽可能多的向后匹配内容。比如: * + ? {m,n}

> 非贪婪模式(懒惰模式): 让匹配重复的元字符尽可能少的向后匹配内容。

- 贪婪模式转换为非贪婪模式

在对应的匹配重复的元字符后加 '?' 号即可

```
*  ->  *?
+  ->  +?
?  ->  ??
{m,n} -> {m,n}?
```

```
e.g.
In : re.findall(r'\(.+?\)',"(abcd)efgh(higk)")
Out: ['(abcd)', '(higk)']
```

2.3.3 正则表达式分组

- 定义

在正则表达式中，以()建立正则表达式的内部分组，子组是正则表达式的一部分，可以作为内部整体操作对象。

- 作用 : 可以被作为整体操作，改变元字符的操作对象

```
e.g.  改变 +号 重复的对象
In : re.search(r'(ab)+',"abababababab").group()
Out: 'abababababab'

e.g. 改变 |号 操作对象
In : re.search(r'(王|李)\w{1,3}',"王者荣耀").group()
Out: '王者荣耀'
```

- 捕获组

捕获组本质也是一个子组，只不过拥有一个名称用以表达该子组的意义，这种有名称的子组即为捕获组。

> 格式：`(?P<name>pattern)`

```
e.g. 给子组命名为 "pig"
In : re.search(r'(?P<pig>ab)+',"abababababab").group('pig')
Out: 'ab'
In [5]: re.search(r'(?P<pig>ab)+',"abababababab").group()
Out[5]: 'abababababab'

```

- 注意事项

- 一个正则表达式中可以包含多个子组
- 子组可以嵌套但是不宜结构过于复杂
- 子组序列号一般从外到内，从左到右计数

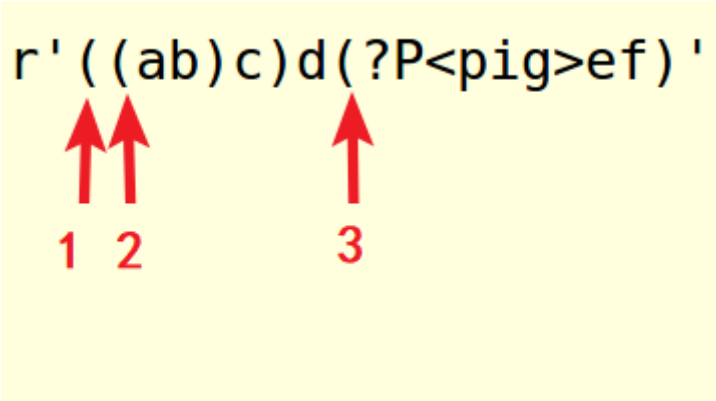

2.3.4 正则表达式匹配原则

1. 正确性,能够正确的匹配出目标字符串.
2. 排他性,除了目标字符串之外尽可能少的匹配其他内容.
3. 全面性,尽可能考虑到目标字符串的所有情况,不遗漏.

2.4 Python re模块使用

2.4.1 基础函数使用

```
regex = compile(pattern,flags = 0)
功能: 生产正则表达式对象
参数: pattern  正则表达式
      flags  功能标志位,扩展正则表达式的匹配
返回值: 正则表达式对象
```

```
re.findall(pattern,string,flags = 0)
功能: 根据正则表达式匹配目标字符串内容
参数: pattern  正则表达式
      string 目标字符串
      flags  功能标志位,扩展正则表达式的匹配
返回值: 匹配到的内容列表,如果正则表达式有子组则只能获取到子组对应的内容
```

```
regex.findall(string,pos,endpos)
功能: 根据正则表达式匹配目标字符串内容
参数: string 目标字符串
      pos 截取目标字符串的开始匹配位置
      endpos 截取目标字符串的结束匹配位置
返回值: 匹配到的内容列表,如果正则表达式有子组则只能获取到子组对应的内容
```

```
re.split(pattern,string,max, flags = 0)
功能: 使用正则表达式匹配内容,切割目标字符串
参数: pattern  正则表达式
      string 目标字符串
      max 最多切割几部分
      flags  功能标志位,扩展正则表达式的匹配
返回值: 切割后的内容列表
```

```
re.sub(pattern,replace,string,count,flags = 0)
功能: 使用一个字符串替换正则表达式匹配到的内容
参数: pattern  正则表达式
      replace  替换的字符串
      string 目标字符串
      count  最多替换几处,默认替换全部
      flags  功能标志位,扩展正则表达式的匹配
返回值: 替换后的字符串
```

```
"""
re模块演示1
"""
import re

```

```python
# 目标字符串
s = "Alex:1996,Sunny:1998"
pattern = r"(\w+):(\d+)"  # 正则表达式
# pattern = r"\w+:\d+"  # 正则表达式

# re直接调用
l = re.findall(pattern,s)
print(l)

# 生成正则表达式对象
regex = re.compile(pattern)
l = regex.findall(s,0,13)  # 目标字符串变为 s[0:13]
print(l)

# 使用正则表达式匹配内容分割字符串
l = re.split(r"\W+",s,2)
print(l)

# 替换目标字符串中匹配到的内容
s = re.sub(r"\W+",'##',s,2)
print(s)
-------------------------------------------------
[('Alex', '1996'), ('Sunny', '1998')]
[('Alex', '1996')]
['Alex', '1996', 'Sunny:1998']
Alex##1996##Sunny:1998
```

2.4.2 生成match对象

```
re.finditer(pattern,string,flags = 0)
功能: 根据正则表达式匹配目标字符串内容
参数: pattern  正则表达式
      string 目标字符串
      flags  功能标志位,扩展正则表达式的匹配
返回值: 匹配结果的迭代器
```

```
re.match(pattern,string,flags=0)
功能：匹配某个目标字符串开始位置
参数：pattern 正则
    string  目标字符串
返回值：匹配内容match object 没有匹配到返回None
```

```
re.search(pattern,string,flags=0)
功能：匹配目标字符串第一个符合内容
参数：pattern 正则
    string  目标字符串
返回值：匹配内容match object 没有匹配到返回None
```

```
"""
re模块示例，生成match对象
```

```
3
4  一个match对象对应一处匹配内容
5  用于获取匹配到内容的详细信息
6  """
7
8  import re
9
10 s = "时，2020年春，AID 2002 班开课"
11 # s = "2020年春，AID 2002 班开课"
12
13 pattern = r"\d+"
14
15 # 匹配返回迭代器
16 it = re.finditer(pattern ,s)
17
18 for i in it:
19     print(i.group())  # 得到match对象
20
21 # 匹配开头位置
22 # obj = re.match(pattern,s)
23 # print(obj.group())
24
25 # 匹配第一处
26 obj = re.search(pattern,s)
27 print(obj.group())
28
29
```

2.4.3 match对象使用

- span() 获取匹配内容的起止位置，返回2元元组
- groupdict() 获取捕获组字典，组名为键，对应内容为值
- groups() 获取子组对应内容，返回元组
- group(n = 0)

  功能：获取match对象匹配内容
  参数：默认为0表示获取整个match对象内容，如果是序列号或者组名则表示获取对应子组内容
  返回值：匹配字符串

```
1  """
2  match对象使用
3  """
4
5  import re
6
7  s = "abcdefghi"
8  pattern = "(ab)cd(?P<dog>ef)"
9
10 obj = re.search(pattern,s)  # 获取match对象
11
12 print(obj.span())  # s[0:6] 获取匹配到的内容在目标字符串中的位置
13 print(obj.groupdict()) # 获取捕获组字典 组名为键，匹配到的内容为值
14 print(obj.groups()) # 获取子组匹配到的内容
15 print(obj.group()) # 获取匹配内容
16 ----------------------------------------------
17 (0, 6)
```

```
{'dog': 'ef'}
('ab', 'ef')
abcdef
```

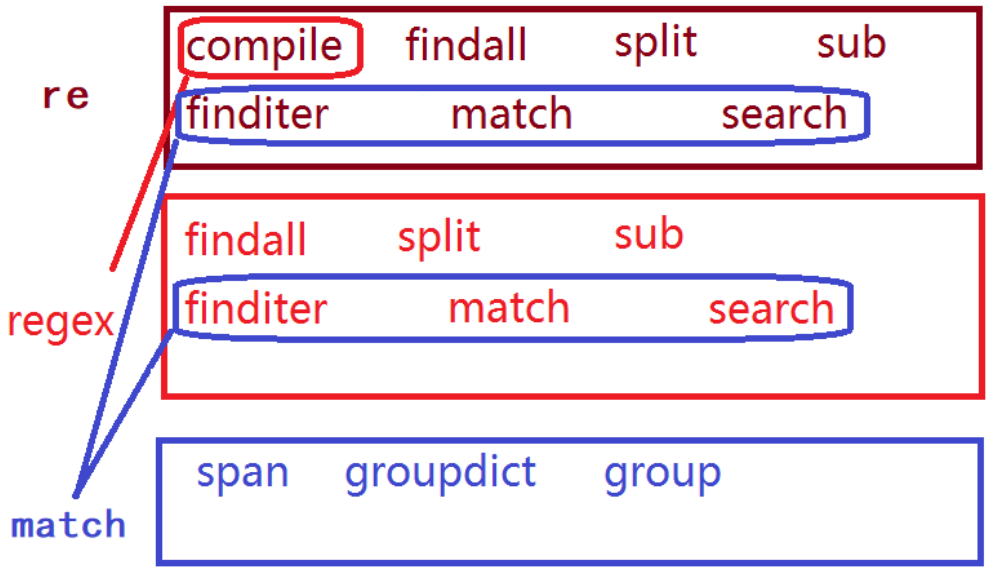

2.4.4 flags参数扩展

- 作用函数：re模块调用的匹配函数。如：re.compile,re.findall,re.search....
- 功能：扩展丰富正则表达式的匹配功能
- 常用flag

```
A == ASCII  元字符只能匹配ascii码

I == IGNORECASE  匹配忽略字母大小写

S == DOTALL  使 . 可以匹配换行

M == MULTILINE  使 ^  $可以匹配每一行的开头结尾位置
```

> 注意：同时使用多个flag，可以用竖线连接 flags = re.I | re.A